



REGRESSÃO LINEAR

APRENDIZAGEM DE MÁQUINA

CST em Desenvolvimento de Software Multiplataforma



PROF. Me. TIAGO A. SILVA



O QUE É REGRESSÃO LINEAR?

- É um dos algoritmos mais fundamentais e amplamente utilizados no campo do aprendizado de máquina:
 - Sua simplicidade, interpretabilidade e eficiência computacional a tornam a **porta de entrada** para a compreensão de modelos preditivos.
- Em sua essência, a regressão linear busca estabelecer uma relação linear entre uma **variável dependente** (aquilo que queremos prever) e uma ou mais variáveis independentes (os fatores que influenciam a previsão).

O QUE É REGRESSÃO LINEAR?

- Imagine que você queira prever o preço de um imóvel. Intuitivamente, sabemos que o tamanho da casa é um fator crucial.
- A regressão linear formaliza essa intuição ao tentar traçar uma linha reta que melhor se ajusta a um conjunto de dados, onde cada ponto representa um imóvel com seu respectivo tamanho e preço.
- O objetivo é que essa linha, chamada de **linha de regressão**, seja capaz de estimar o preço de um novo imóvel com base em seu tamanho.

TIPOS DE REGRESSÃO LINEAR

- **Regressão Linear Simples:** Envolve apenas uma variável independente para prever a variável dependente. Por exemplo, prever o salário de uma pessoa com base em seus anos de experiência.
- **Regressão Linear Múltipla:** Utiliza duas ou mais variáveis independentes. No exemplo do imóvel, poderíamos incluir, além do tamanho, o número de quartos, a localização e a idade do imóvel para uma previsão mais precisa do preço.

COMO SABER SE UM MODELO É BOM?

- Para que um modelo de regressão linear seja confiável, algumas premissas devem ser atendidas:
 - A linearidade na relação entre as variáveis,
 - A independência dos erros (os erros de previsão não devem ter um padrão),
 - A homocedasticidade (a variância dos erros deve ser constante) e a normalidade na distribuição dos resíduos (erros).

A BASE MATEMÁTICA DO MODELO

Equações que são implementadas em Python

A EQUAÇÃO DO MODELO LINEAR


$$\hat{y} = a + b \cdot x + e$$

- Onde:
 - $\hat{y}$ é Variável **DEPENDENTE** ou variável **EXPLICADA**.
 - x é Variável **INDEPENDENTE** ou variável **EXPLICATIVA**.
 - e é Erro associado ao processo de determinação dos valores de y com base em x (e são os resíduos).
- O modelo de **Regressão Linear Simples** fica resumido a:

$$\hat{y} = a + b \cdot x$$

A EQUAÇÃO DO MODELO LINEAR

- O processo de estimação do modelo gera uma reta (a reta de regressão ou reta de ajuste ótimo) que produz os erros mínimos em relação aos pontos (pares ordenados – mapa de dispersão).



CÁLCULO DA RETA DE REGRESSÃO

$$\hat{y} = a + b \cdot x$$

$$a = \frac{\Sigma y - b \cdot \Sigma x}{n}$$

$$b = \frac{n \cdot (\Sigma xy) - (\Sigma x \cdot \Sigma y)}{n \cdot (\Sigma x^2) - (\Sigma x)^2}$$

Tamanho do Imóvel (x , em m²)	Preço (y , em mil reais)	x²	y²	xy
50	150	2.500	22.500	7.500
60	200	3.600	40.000	12.000
70	250	4.900	62.500	17.500
80	300	6.400	90.000	24.000
90	350	8.100	122.500	31.500
100	400	10.000	160.000	40.000
110	420	12.100	176.400	46.200
120	450	14.400	202.500	54.000
130	470	16.900	220.900	61.100
140	500	19.600	250.000	70.000
950	3.490	98.500	1.347.300	363.800

CÁLCULO DA RETA DE REGRESSÃO: CALCULANDO b

$$b = \frac{10 \cdot (363800) - (950 \cdot 3490)}{10 \cdot (98500) - (950)^2} = \frac{3638000 - 3315500}{985000 - 902500} = \frac{322500}{82500} \approx 3,9091$$

$$b = \frac{n \cdot (\sum xy) - (\sum x \cdot \sum y)}{n \cdot (\sum x^2) - (\sum x)^2}$$

Tamanho do Imóvel (x , em m²)	Preço (y , em mil reais)	x ²	y ²	xy
50	150	2.500	22.500	7.500
60	200	3.600	40.000	12.000
70	250	4.900	62.500	17.500
80	300	6.400	90.000	24.000
90	350	8.100	122.500	31.500
100	400	10.000	160.000	40.000
110	420	12.100	176.400	46.200
120	450	14.400	202.500	54.000
130	470	16.900	220.900	61.100
140	500	19.600	250.000	70.000
950	3.490	98.500	1.347.300	363.800

CÁLCULO DA RETA DE REGRESSÃO: CALCULANDO a

$$a = \frac{3490 - (3,9091 \times 950)}{10} = \frac{3490 - 3713,645}{10} = \frac{-223,645}{10} = -22,3645$$

$$a = \frac{\Sigma y - b \cdot \Sigma x}{n}$$

Tamanho do Imóvel (x , em m²)	Preço (y , em mil reais)	x ²	y ²	xy
50	150	2.500	22.500	7.500
60	200	3.600	40.000	12.000
70	250	4.900	62.500	17.500
80	300	6.400	90.000	24.000
90	350	8.100	122.500	31.500
100	400	10.000	160.000	40.000
110	420	12.100	176.400	46.200
120	450	14.400	202.500	54.000
130	470	16.900	220.900	61.100
140	500	19.600	250.000	70.000
950	3.490	98.500	1.347.300	363.800

CÁLCULO DA RETA DE REGRESSÃO: SUBSTITUINDO VALORES


$$\hat{y} = -22,3645 + 3,9091 \cdot x$$

$$\hat{y} = a + b \cdot x$$

Tamanho do Imóvel (x , em m²)	Preço (y , em mil reais)	x ²	y ²	xy
50	150	2.500	22.500	7.500
60	200	3.600	40.000	12.000
70	250	4.900	62.500	17.500
80	300	6.400	90.000	24.000
90	350	8.100	122.500	31.500
100	400	10.000	160.000	40.000
110	420	12.100	176.400	46.200
120	450	14.400	202.500	54.000
130	470	16.900	220.900	61.100
140	500	19.600	250.000	70.000
950	3.490	98.500	1.347.300	363.800

CÁLCULO DA RETA DE REGRESSÃO: SUBSTITUINDO VALORES

Regressão Linear e Coeficiente de Determinação (R^2)



$$\hat{y} = -22,3645 + 3,9091 \cdot x$$

O QUÃO BOM O MODELO DE PREVISÃO É?

- A análise de correlação determina um número que expressa uma medida numérica do grau da relação encontrada entre duas variáveis.
- É, efetivamente, uma medida do grau e da direção de uma relação linear entre duas variáveis.
- O nome correto desta análise é **Coefficiente de Correlação** produto dos momentos de **Pearson** (r). É dado pela equação a seguir.

COEFICIENTE DE CORRELAÇÃO: r

$$r = \frac{n \cdot \Sigma xy - (\Sigma x) \cdot (\Sigma y)}{\sqrt{n \cdot \Sigma x^2 - (\Sigma x)^2} \cdot \sqrt{n \cdot \Sigma y^2 - (\Sigma y)^2}}$$


- Faixa de Variação de r : $-1 \leq r \leq 1$
- Onde:
 - Próximo de $-1 \rightarrow$ Forte correlação negativa;
 - Próximo de $1 \rightarrow$ Forte correlação positiva.
 - Próximo de $0 \rightarrow$ Não há correlação significativa.

COEFICIENTE DE DETERMINAÇÃO: r^2

$$r^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Faixa de Variação de r^2 : $0 \leq r^2 \leq 1$
- Onde:
 - Próximo de 1 $\rightarrow$ Forte poder de explicação do modelo (reta de regressão)
 - Próximo de 0 $\rightarrow$ Fraco poder de explicação do modelo (reta de regressão);

IMPLEMENTAÇÃO NO JUPYTER NOTEBOOK



OBRIGADO!

- Encontre este **material on-line** em:
 - Slides: Plataforma Google Classroom
- Em caso de **dúvidas**, entre em contato:
 - **Prof. Me. Tiago:** tiago.silva@cps.sp.gov.br

